

## 约束非线性问题:

$$\begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \leq 0, \quad i = 1, \dots, l \\ \quad h_j(x) = 0, \quad j = 1, \dots, m \end{cases}$$

### 解法分类:

#### 1、将约束问题转化为一个或一系列无约束问题

基本思想: 根据约束条件改造原目标函数, 构造同时表达原目标函数和约束条件的无约束新目标函数, 然后求解。

对不等式约束和等式约束都适用。


#### 2、直接求解约束问题

基本思想: 直接在可行域中寻找约束最优解。

此类方法只适用于不等式约束问题。


对约束问题，可先作一些尝试或转换处理，以便于求解

# 1、先不考虑约束条件，求目标函数的无约束最优点



(1) 无约束极值点  $\mathbf{x}^{(0)} \in S$

即为所求



(2) 无约束极值点  $\mathbf{x}^{(0)} \notin S$

需使用约束问题解法进一步求解

## 2、用消元法消去某些比较简单的等式约束

设问题中存在 $m$ 个等式约束

$$\left\{ \begin{array}{l} h_1(x_1, x_2, \dots, x_n) = 0 \\ h_2(x_1, x_2, \dots, x_n) = 0 \\ \dots \dots \dots \dots \dots \dots \dots \\ h_m(x_1, x_2, \dots, x_n) = 0 \end{array} \right.$$

假定可从这 $m$ 个方程中解出 $m$ 个变量来，例如后面的 $m$ 个变量 $x_{n-m+1}, \dots, x_n$ 表达为其余的 $n-m$ 个变量的显函数：

$$\left\{ \begin{array}{l} x_{n-m+1} = f_1(x_1, x_2, \dots, x_{n-m}) \\ x_{n-m+2} = f_2(x_1, x_2, \dots, x_{n-m}) \\ \dots \dots \dots \dots \dots \dots \dots \\ x_n = f_m(x_1, x_2, \dots, x_{n-m}) \end{array} \right.$$

将上述函数关系代入原目标函数及余下的各约束中，则构成的新问题为仅含  $n-m$  个变量的约束问题。

对简单的等式约束问题，可通过此法简化为无约束问题。

### 3、用自变量变换法去掉某些简单的不等式约束

如 
$$\begin{cases} \min f(\mathbf{x}) = \min f(x_1, x_2, \dots, x_n) \\ \text{s.t. } x_i \geq 0 \quad i=1, 2, \dots, n \end{cases}$$

若令  $x_i = y_i^2$  ( $i=1, 2, \dots, n$ ), 则原问题简化为

$$\min f'(y_1, y_2, \dots, y_n) = \min f(y_1^2, y_2^2, \dots, y_n^2)$$

求出  $\mathbf{y}^*$ , 经反变换得  $\mathbf{x}^*$



可行域不能变

变换原则:

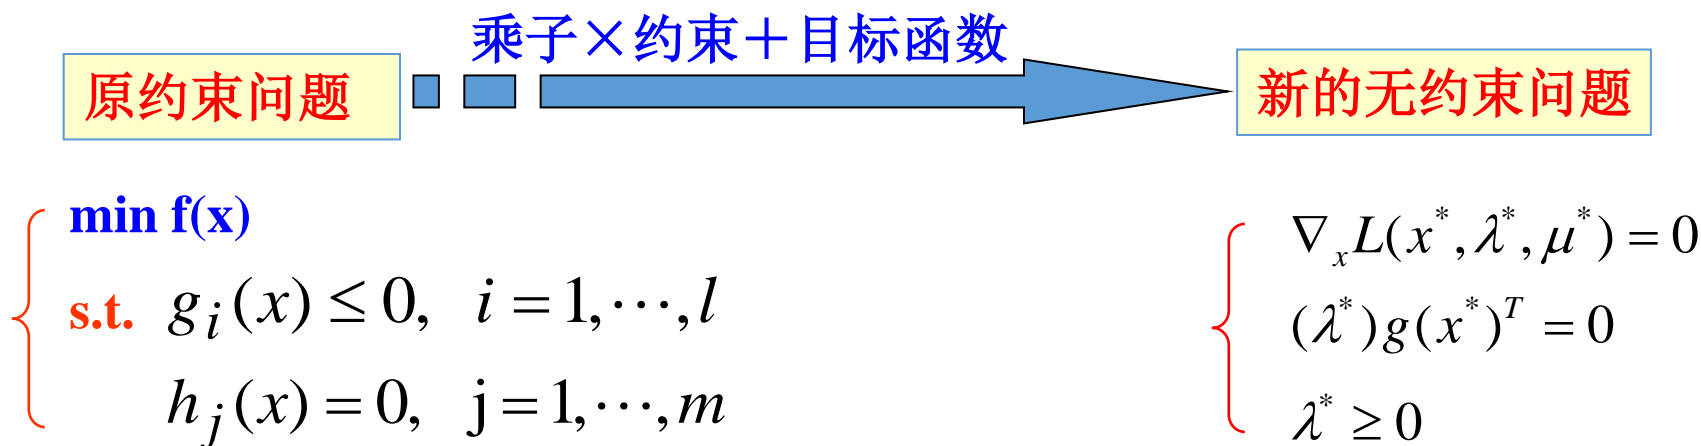
- (1)  $y_i$  取任何实数都要使  $x_i(y_i)$  满足原约束条件;
- (2) 对每个  $x_i$  的可行值必须存在相应的  $y_i$  值, 使  $x_i = y_i^2$  成立。

问题: 1、导致目标函数形式变得更复杂

2、有局限性

# Lagrange乘子法

理论基础：约束问题的最优性必要条件，即 KKT条件



引入Lagrange函数

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^l \lambda_i g_i(x) + \sum_{j=1}^m \mu_j h_j(x)$$

和向量函数  $\mathbf{g}(\mathbf{x}) = [g_1(\mathbf{x}), g_2(\mathbf{x}), \dots, g_l(\mathbf{x})]^T$

## 等式约束问题的Lagrange乘子法

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } h_j(\mathbf{x}) = 0 \quad j=1,2,\dots,m \end{cases}$$

$$\text{K-T条件: } \nabla f(\mathbf{x}^*) + \sum_{j=1}^m \mu_j^* \nabla h_j(\mathbf{x}^*) = 0 \quad \text{n个方程}$$

$$\text{约束条件: } h_j(\mathbf{x}^*) = 0 \quad j=1,2,\dots,m \quad \text{m个方程}$$

$\Rightarrow$  **n+m个变量**

引入Lagrange函数  $L(\mathbf{x}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{j=1}^m \mu_j h_j(\mathbf{x})$

$$\nabla L(\mathbf{x}, \boldsymbol{\mu}) = 0 \Rightarrow \begin{cases} \partial L / \partial x_i = 0 & i = 1, 2, \dots, n \\ \partial L / \partial \mu_j = 0 & j = 1, 2, \dots, m \end{cases}$$

$\Rightarrow$  **Lagrange函数的平稳点**

方程组  $\begin{cases} \partial L / \partial x_i = 0 & i = 1, 2, \dots, n \\ \partial L / \partial \mu_j = 0 & j = 1, 2, \dots, m \end{cases}$  的求解, 可转化为求解下列无约束问题

$$\min z(x_1, x_2, \dots, x_n; \mu_1, \dots, \mu_m) = \sum_{i=1}^n \left[ \frac{\partial L}{\partial x_i} \right]^2 + \sum_{j=1}^m [h_j(x)]^2$$

该问题的极小点就是  $L(x, \mu)$  的平稳点, 其分量  $x_1^*, \dots, x_n^*$  是原约束问题的最优点。

**例** 用Lagrange乘子法求解问题

$$\min f(x) = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2$$

$$\text{s.t. } h(x) = x_1 + x_2 - 8 = 0$$

**解:** 引入Lagrange函数

$$L = f + \mu h = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2 + \mu(x_1 + x_2 - 8)$$

求  $L(x_1, x_2, \mu)$  的平稳点, 即解方程组

$$\begin{cases} \partial L / \partial x_1 = -10 + 2x_1 - x_2 + \mu = 0 \\ \partial L / \partial x_2 = -4 + 2x_2 - x_1 + \mu = 0 \\ \partial L / \partial \mu = x_1 + x_2 - 8 = 0 \end{cases} \quad \Rightarrow \quad \begin{cases} x_1^* = 5 \\ x_2^* = 3 \\ \mu^* = 3 \end{cases}$$

原问题的最优点  $x^* = [5, 3]^T$ , 最优解  $f^* = 12$

对等式约束问题:

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } h_j(\mathbf{x}) = 0 \quad j=1,2,\dots,m \end{cases}$$

引入Lagrange函数  $L(\mathbf{x}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{j=1}^m \mu_j h_j(\mathbf{x})$

$$\nabla L(\mathbf{x}, \boldsymbol{\mu}) = 0 \Rightarrow \begin{cases} \partial L / \partial x_i = 0 & i = 1, 2, \dots, n \\ \partial L / \partial \mu_j = 0 & j = 1, 2, \dots, m \end{cases} \Rightarrow \text{Lagrange函数的平稳点}$$

$$\min z(x_1, x_2, \dots, x_n; \mu_1, \dots, \mu_n) = \sum_{i=1}^n \left[ \frac{\partial L}{\partial x_i} \right]^2 + \sum_{j=1}^m [h_j(\mathbf{x})]^2$$

该问题的极小点就是 $L(\mathbf{x}, \boldsymbol{\mu})$ 的平稳点。

Lagrange函数 $L$ 只是 $\mu_j$ 的线性函数，在 $n+m$ 维空间中，它的平稳点不会是 $L(\mathbf{x}, \boldsymbol{\mu})$ 的极值点，以此不能采用无约束问题优化方法，通过求 $\min L(\mathbf{x}, \boldsymbol{\mu})$ 的最小点来求 $L(\mathbf{x}, \boldsymbol{\mu})$ 的平稳点。



## 不等式约束问题的Lagrange乘子法

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, l \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{cases}$$

可否直接求解其K-T条件？

$$\begin{cases} \nabla f(\mathbf{x}^*) + \sum_{i=1}^l \lambda_i^* \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \mu_j^* \nabla h_j(\mathbf{x}^*) = 0 \\ \lambda_i^* g_i(\mathbf{x}^*) = 0 \quad i = 1, \dots, l \\ \lambda_i^* \geq 0 \quad i = 1, \dots, l \end{cases}$$

当然可以！

但一般作法是引入 $l$ 个松弛变量 $w_i$  ( $i=1, \dots, l$ ), 把原问题化为仅有等式约束的问题

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) + w_i^2 = 0, \quad i = 1, \dots, l \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{cases}$$

为了不出现新的  
不等式约束 $w_i > 0$

引入Lagrange函数  $L(\mathbf{x}, \mu, \mathbf{w}) = f(\mathbf{x}) + \sum_{j=1}^m \mu_j h_j(\mathbf{x}) + \sum_{k=1}^l \mu_{k+m} [g_k(\mathbf{x}) + w_k^2]$

求 $L(x, \mu, w)$ 的平稳点, 即解方程组

$$\left\{ \begin{array}{ll} \partial L / \partial x_i = 0 & i = 1, 2, \dots, n \\ \partial L / \partial \mu_j = 0 & j = 1, 2, \dots, m+l \\ \partial L / \partial w_k = 2\mu_{k+m} w_k = 0 & k = 1, 2, \dots, l \end{array} \right.$$

上述方程组的求解可转化为求解一个最小二乘问题, 相应目标函数为

$$z = \sum_{i=1}^n \left[ \frac{\partial L}{\partial x_i} \right]^2 + \sum_{j=1}^m [h_j(x)]^2 + \sum_{k=1}^l [g_k(x) + w_k^2]^2 + \sum_{k=1}^l (2\mu_{k+m} w_k)^2$$

## 例 用Lagrange乘子法求解问题

$$\left\{ \begin{array}{l} \min f(\mathbf{x}) = 2x_1^2 - 2x_1x_2 + 2x_2^2 - 6x_1 \\ \text{s.t. } g_1(\mathbf{x}) = 3x_1 + 4x_2 - 6 \leq 0 \\ \quad \quad g_2(\mathbf{x}) = -x_1 + 4x_2 - 2 \leq 0 \end{array} \right.$$

解：引入松弛变量 $x_3$ 和 $x_4$ ，把不等式约束变为等式约束

$$G_1(\mathbf{x}) = 3x_1 + 4x_2 + x_3^2 - 6 = 0$$

$$G_2(\mathbf{x}) = -x_1 + 4x_2 + x_4^2 - 2 = 0$$

构造Lagrange函数

$$L(\mathbf{x}, \mu) = (2x_1^2 - 2x_1x_2 + 2x_2^2 - 6x_1) + \mu_1(3x_1 + 4x_2 + x_3^2 - 6) + \mu_2(-x_1 + 4x_2 + x_4^2 - 2)$$

求 $L(\mathbf{x}, \mu)$ 的平稳点，即解方程组

$$\partial L / \partial x_1 = 4x_1 - 2x_2 - 6 + 3\mu_1 - \mu_2 = 0$$

$$\partial L / \partial x_2 = -2x_1 + 4x_2 + 4\mu_1 + 4\mu_2 = 0$$


$$\partial L / \partial x_3 = 2\mu_1 x_3 = 0$$

$$\partial L / \partial x_4 = 2\mu_2 x_4 = 0$$

$$\partial L / \partial \mu_1 = 3x_1 + 4x_2 + x_3^2 - 6 = 0$$

$$\partial L / \partial \mu_2 = -x_1 + 4x_2 + x_4^2 - 2 = 0$$

最小二乘法解方程组



由此可见，一个约束问题的一组最优解都对应存在一组确定的Lagrange乘子，也就是说，Lagrange乘子是该约束问题的一组特征值。

Lagrange乘子法可求解所有约束问题，它实质上是一种解析的间接解法，理论上重要。

但其缺点是：维数增加很多，函数形式复杂，最后归结为用最小二乘法解一个非线性方程组，所以不能算是一种很有效的方法。

## § 惩罚函数法

理论和实践价值都大，是求解约束问题的有效方法之一。

**出发点：** 将一个约束问题转换为一个或一系列的无约束问题进行求解。

### § 外部惩罚函数法（外点法）

#### （一）基本思想

$$\text{对约束问题} \begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \leq 0, \quad i = 1, \dots, l \\ h_j(x) = 0, \quad j = 1, \dots, m \end{cases}$$

想办法构造一个新的目标函数，使得在原问题可行域S内，它的值与原问题目标函数值相同，在可行域S之外，它给出一个正无穷大的“惩罚”值，即

$$F(x) = \begin{cases} f(x), & x \in S \\ +\infty, & x \notin S \end{cases}$$

求解  $F(x)$  的无约束极小值，极小点必定在S中，从而得到原问题极小点。


这样将原约束问题转化为一个无约束问题进行求解。

## 如何表达 $F(x)$ ??? 因为其中出现了 $+\infty$

**对策：** 设法构造一系列的函数  $F(x,M)$ ，不断增大  $M$ ，使  $F(x,M)$  逐步向  $F(x)$  逼近。

在  $S$  内， $F(x,M)$  的值与  $f(x)$  相同，在  $S$  之外，给出一个大的“惩罚值”。

对每个  $M$ ，可求得  $F(x,M)$  的极小点  $x^*(M)$ ，当  $M \rightarrow +\infty$ ， $x^*(M) \rightarrow x^*$



惩罚函数可构造如下


$$F(x, M) = f(x) + M P(x) = f(x) + M \left\{ \sum_{i=1}^l [\max(0, g_i(x))]^2 + \sum_{j=1}^m [h_j(x)]^2 \right\}$$

惩罚因子

惩罚项

当约束不满足时，要么某些 $g_i(x) > 0$ ，要么某些 $h_j(x) \neq 0$ ，当 $M$ 很大时， $F(x, M)$ 非常大，这是对不可行点的惩罚，使该点不会成为约束问题的极小点。

当约束满足时，惩罚项 $P(x) = 0$ ，故 $F(x, M) = f(x)$ ，没有受到惩罚。



由于 $x^*(M)$ 通常是从可行域外部趋于 $x^*$ 的，所以上式确定的惩罚函数称为外部惩罚函数。这种解法称为外部惩罚函数法或外点法。



## 例1 用外点法求解问题

$$\begin{cases} \min f(\mathbf{x}) = (x_1 - 4)^2 + (x_2 - 4)^2 \\ \text{s.t. } h(\mathbf{x}) = x_1 + x_2 - 5 = 0 \end{cases}$$

**解：**构造惩罚函数  $F(\mathbf{x}, M) = (x_1 - 4)^2 + (x_2 - 4)^2 + M(x_1 + x_2 - 5)^2$

求 $F(\mathbf{x}, M)$ 的平稳点。对简单问题，可用解析法求解。即解方程组

$$\begin{cases} \partial F / \partial x_1 = 2(x_1 - 4) + 2M(x_1 + x_2 - 5) = 0 \\ \partial F / \partial x_2 = 2(x_2 - 4) + 2M(x_1 + x_2 - 5) = 0 \end{cases}$$

解得  $x_1^*(M) = x_2^*(M) = (5M + 4) / (2M + 1)$

$M=0, x_1(M) = x_2(M) = 4$


$M=0.1, x_1(M) = x_2(M) = 3.73$

$M=1, x_1(M) = x_2(M) = 3$

$M=10, x_1(M) = x_2(M) = 2.5174$

$M=100, x_1(M) = x_2(M) = 2.5075$

令  $M \rightarrow +\infty$ , 得  $x_1^*(M) = x_2^*(M) \rightarrow 2.5$



## 例2 用外点法解

$$\begin{cases} \min f(x) = (x_1 - 4)^2 + (x_2 - 4)^2 \\ \text{s.t. } g(x) = x_1 + x_2 - 5 \leq 0 \end{cases}$$

解：可行域为直线 $x_1 + x_2 - 5 = 0$  及其左下方的半平面，记为S

$$\begin{aligned} F(x, M) &= (x_1 - 4)^2 + (x_2 - 4)^2 + M[\max(x_1 + x_2 - 5, 0)]^2 \\ &= \begin{cases} (x_1 - 4)^2 + (x_2 - 4)^2 + M(x_1 + x_2 - 5)^2 & x \notin S \\ (x_1 - 4)^2 + (x_2 - 4)^2 & x \in S \end{cases} \end{aligned}$$

(1) 当 $x \notin S$  时

$$\begin{cases} \partial F / \partial x_1 = 2(x_1 - 4) + 2M(x_1 + x_2 - 5) = 0 \\ \partial F / \partial x_2 = 2(x_2 - 4) + 2M(x_1 + x_2 - 5) = 0 \end{cases} \implies x_1^*(M) = x_2^*(M) = (5M + 4) / (2M + 1)$$

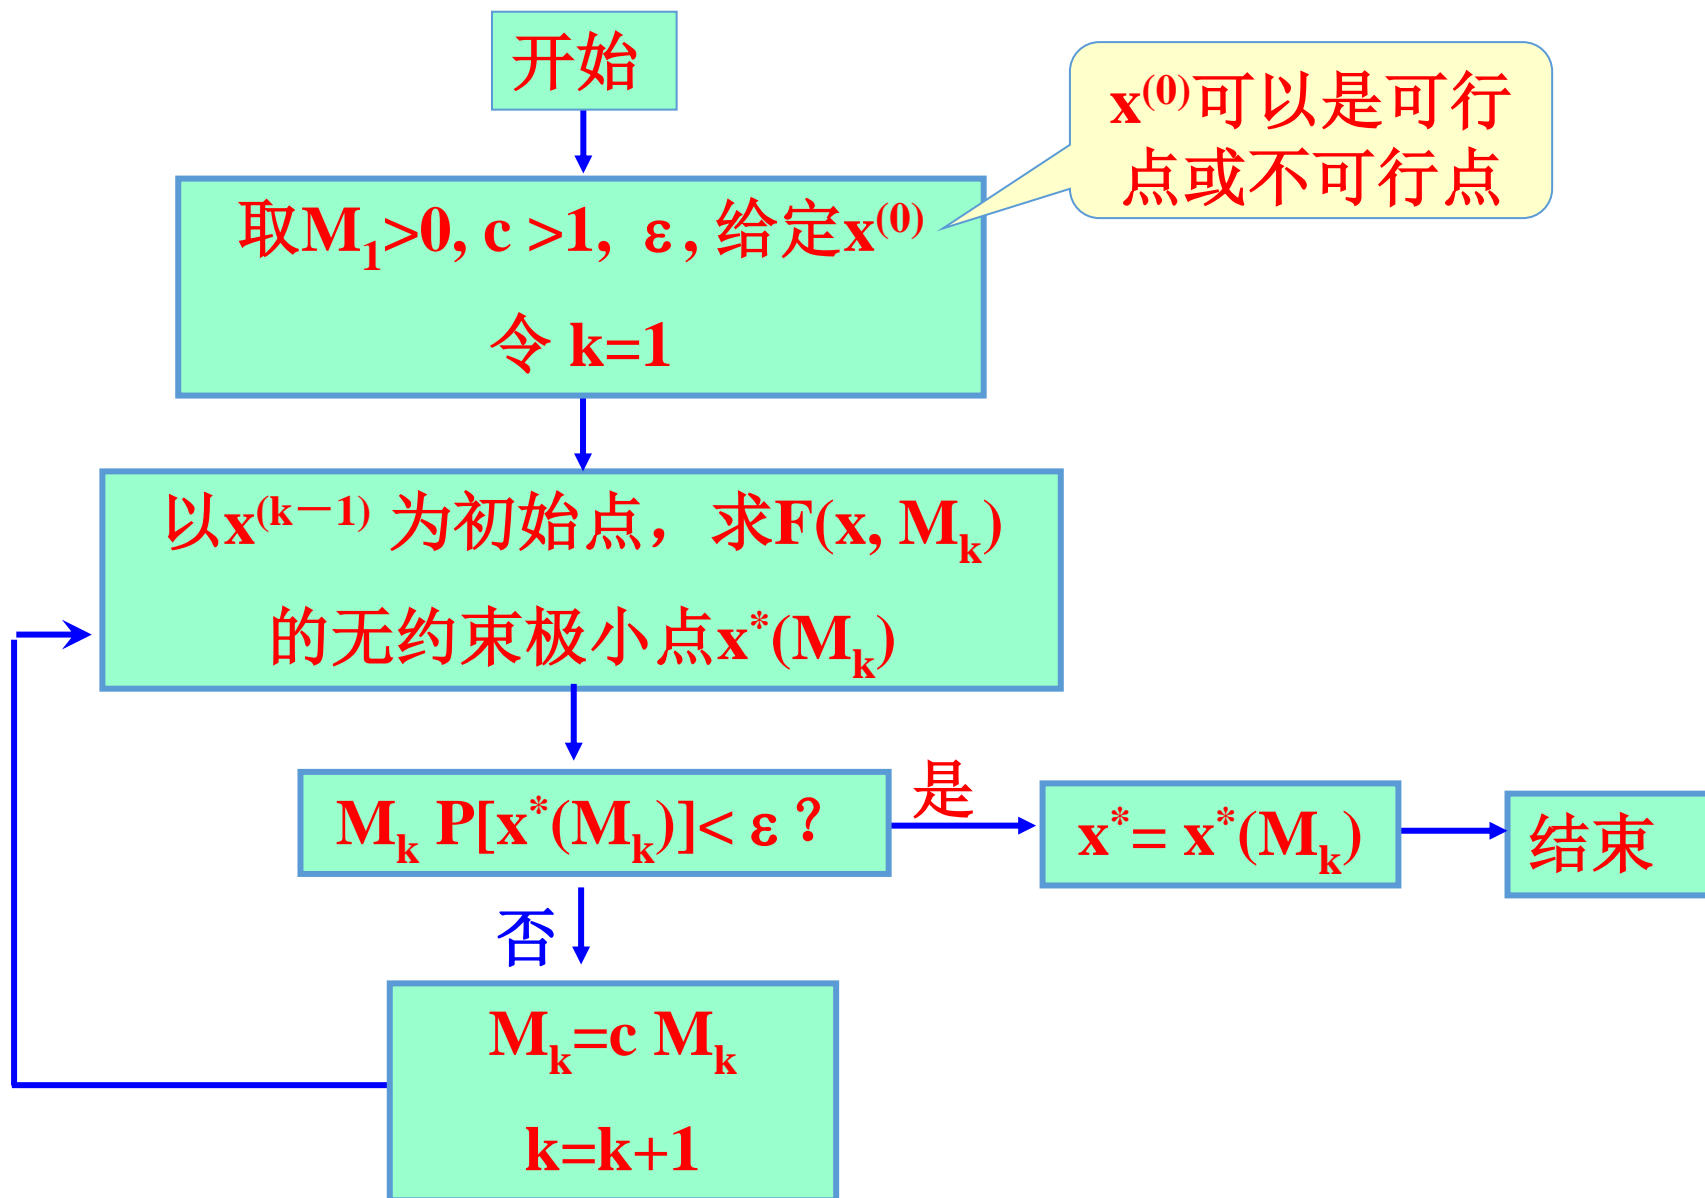
(2) 当 $x \in S$  时

$$\begin{cases} \partial F / \partial x_1 = 2(x_1 - 4) = 0 \\ \partial F / \partial x_2 = 2(x_2 - 4) = 0 \end{cases} \implies x_1 = x_2 = 4$$


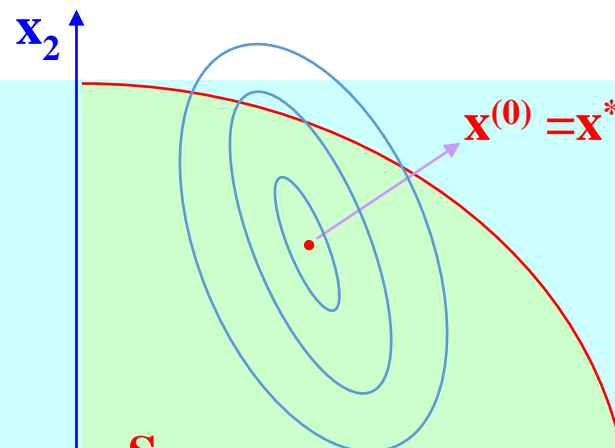


但 $g(4, 4) = 3 > 0$  所以  $[4, 4]^T \notin S$ ，与所设 $x \in S$ 矛盾，故 $\nabla F(x, M) = 0$ 在S中无解。

综合上述两种情况， $x_1^*(M) = x_2^*(M) = (5M + 4) / (2M + 1) \rightarrow 2.5$  (当 $M \rightarrow +\infty$  时)

## (二) 外点法算法



### (三) 关于外点法的几点说明



**定理2** 设原约束问题中 $f, g_i, h_j$ 连续, 最优解 $x^*$ 存在。令 $M_{k+1} \geq M_k > 0$  ( $k=1, 2, \dots$ ),  $M_k \rightarrow +\infty$ 。设对每个 $M_k$ , 惩罚函数 $F(x, M_k)$ 有极小点 $x^*(M_k)$ , 且序列 $\{x^*(M_k)\}$ 收敛到某点  $\tilde{x}$ , 则  $\tilde{x} = x^*$ , 且成立

$$\lim_{k \rightarrow \infty} M_k P[x^*(M_k)] = 0$$

$$\lim_{k \rightarrow \infty} F(x^*(M_k), M_k) = f(x^*) = f^*$$

3、不能一开始就把 $M_k$ 取得很大。

当迭代点离极小点较远时,  $M_k$ 越大,  $F(x, M_k)$ 的Hesse矩阵的条件数越小(矩阵越病态), 从而引起相关数值计算的困难。

矩阵A的条件数  $r(A) = \|A\| \times \|A^{-1}\|$ , 当 $r(A)$ 很小, 称A是病态矩阵

所以只能开始时把 $M_k$ 取得小些, 逐步放大。这样增加了计算量, 有时还得不到满意的结果, 这是外点法的主要缺点。

4、通过求解一系列无约束问题解约束问题的方法, 称为序列无约束极小化技术

## § 2 内部惩罚函数法（内点法）

此法只能求解不等式约束问题，因为要求此法迭代点始终是内点

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) \leq 0 \quad i=1,2,\dots,l \end{cases}$$

### （一）基本思想

在可行域内选取初始点，构造惩罚函数，当迭代点 $\mathbf{x}^{(k)}$ 离边界较远时，给出的惩罚值很小，而当接近 $\mathbf{x}^{(k)}$ 边界时，惩罚值陡然增加，有如在边界上筑起一道“墙”，使迭代点不能越过边界，故此法亦称为“围墙法”、“内点法”。

### （二）内点法的惩罚函数


$$F(\mathbf{x}, \mathbf{r}_k) = f(\mathbf{x}) - \mathbf{r}_k \sum_{i=1}^l \frac{1}{g_i(\mathbf{x})} \quad \text{或} \quad F(\mathbf{x}, \mathbf{r}_k) = f(\mathbf{x}) - \mathbf{r}_k \sum_{i=1}^l \ln[-g_i(\mathbf{x})]$$

$\mathbf{r}_k$ 称为惩罚因子， $\mathbf{r}_k > \mathbf{r}_{k+1} > 0$ ，且  $\lim_{k \rightarrow \infty} \mathbf{r}_k = 0$

上式第二项称为惩罚项，记为 $\mathbf{r}_k \mathbf{B}(\mathbf{x})$ ， $\mathbf{B}(\mathbf{x})$ 称为“围墙”函数

$$F(\mathbf{x}, \mathbf{r}_k) = f(\mathbf{x}) - \mathbf{r}_k \sum_{i=1}^l \frac{1}{g_i(\mathbf{x})}$$

对每个 $\mathbf{r}_k$ ，求 $F(\mathbf{x}, \mathbf{r}_k)$ 的无约束极小点 $\mathbf{x}^*(\mathbf{r}_k)$ ， $\mathbf{r}_k \rightarrow 0$ ， $\mathbf{x}^*(\mathbf{r}_k) \rightarrow \mathbf{x}^*$



随着 $\mathbf{r}_k \rightarrow 0$ ，严厉惩罚的范围向边界靠近，从而使 $F(\mathbf{x}, \mathbf{r}_k) \approx f(\mathbf{x})$ 的范围扩大。

S

若原约束问题的最优解 $\mathbf{x}^*$ 存在，令 $\mathbf{r}_k \geq \mathbf{r}_{k+1} > 0$  ( $k=1, 2, \dots$ )， $\mathbf{r}_k \rightarrow 0$ ；设对每个 $\mathbf{r}_k$ ，惩罚函数 $F(\mathbf{x}, \mathbf{r}_k)$ 有极小点 $\mathbf{x}^*(\mathbf{r}_k)$ ，且序列 $\{\mathbf{x}^*(\mathbf{r}_k)\}$ 收敛到某点 $\tilde{\mathbf{x}}$ ，则 $\tilde{\mathbf{x}} = \mathbf{x}^*$ ，且成立

$$\lim_{k \rightarrow \infty} F(\mathbf{x}^*(\mathbf{r}_k), \mathbf{r}_k) = f(\mathbf{x}^*) = f^*$$

显然，内点法是一种序列无约束极小化方法。

注意点:

(1) 内点法与外点法在求惩罚函数的极小值的问题上有重要区别。

外点法在整个空间求惩罚函数的极小点，而内点法只是在可行域内求极小。


(2) 内点法只在可行域内求惩罚函数的极小点，但实质上还是一个无约束问题。

怎么理解？

因为在惩罚项的作用下， $F(x, r_k)$ 的极小点只能在S的内点上达到，迭代点不会跑到边界上去，所以原问题的约束对 $F(x, r_k)$ 的极小点 $x^*(r_k)$ 来说，都是不起作用的约束。所以求 $F(x, r_k)$ 的极小点 $x^*(r_k)$ 时，可用各种无约束问题的解法。

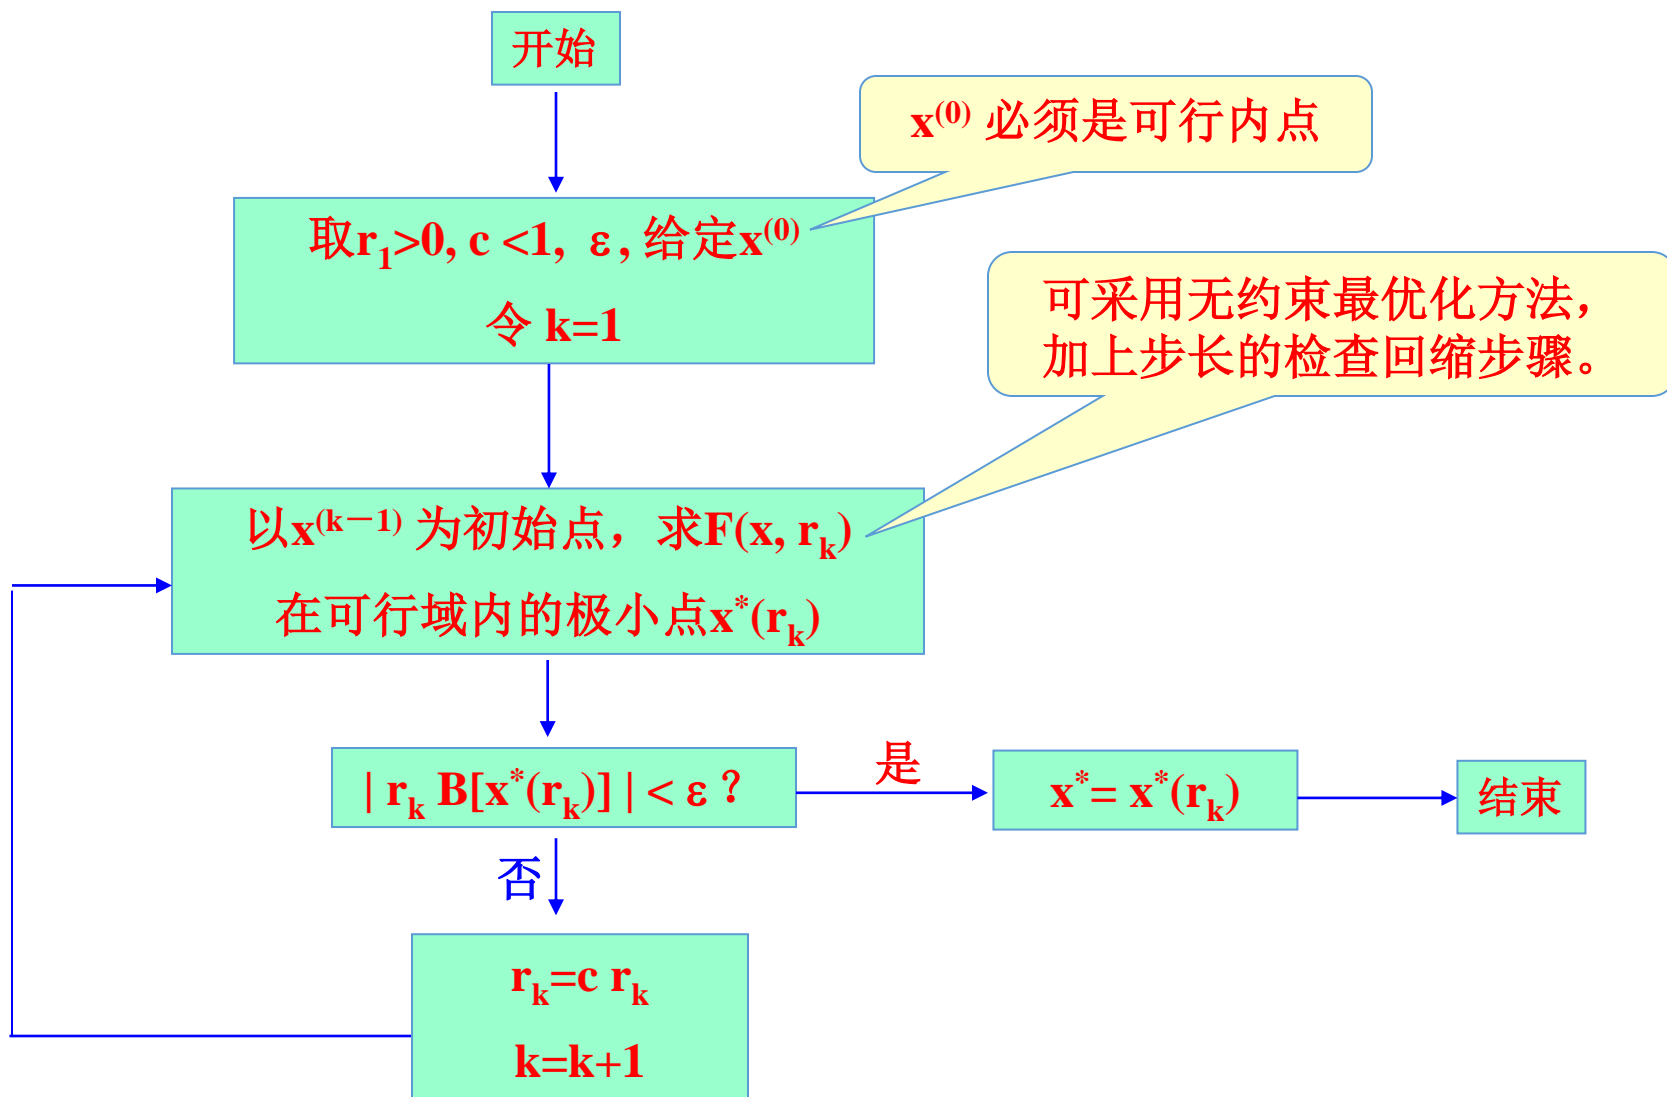
但是在使用搜索法时，如果步长取得太大，迭代点有可能越过边界。

为避免这种情况发生，迭代过程中应检验  $g_i(x)$  的符号，一旦某些  $g_i(x) > 0$ ，应缩小步长，以保证迭代点为严格的内点。





### (三) 内点法的算法



## 例4 用内点法解

$$\begin{cases} \min f(\mathbf{x}) = (\mathbf{x}_1 - 4)^2 + (\mathbf{x}_2 - 4)^2 \\ \text{s.t. } g(\mathbf{x}) = \mathbf{x}_1 + \mathbf{x}_2 - 5 \leq 0 \end{cases}$$

解：构造惩罚函数


$$F(\mathbf{x}, r_k) = (\mathbf{x}_1 - 4)^2 + (\mathbf{x}_2 - 4)^2 - r_k / (\mathbf{x}_1 + \mathbf{x}_2 - 5)$$

求 $F(\mathbf{x}, r_k)$  的平稳点，即解方程组

$$\begin{cases} \partial F / \partial x_1 = 2(x_1 - 4) + 2r_k (x_1 + x_2 - 5)^{-2} = 0 \\ \partial F / \partial x_2 = 2(x_2 - 4) + 2r_k (x_1 + x_2 - 5)^{-2} = 0 \end{cases}$$

由于  $x_1 = x_2$ ，所以得

$$4x_1^3 - 36x_1^2 + 105x_1 - 100 + 0.5r_k = 0$$



$r_k$	100	10	1	0.1	0.01	0.001→0
$\mathbf{x}_1^*(r_k) = \mathbf{x}_2^*(r_k)$	0.5864	1.7540	2.2340	2.4113	2.4714	2.4909 → 2.5 = $\mathbf{x}^*$
$f(\mathbf{x}^*(r_k))$	23.3053	10.0890	6.2375	5.0479	4.6732	4.5548 → 4.5 = $f(\mathbf{x}^*)$
$F(\mathbf{x}^*(r_k), r_k)$	49.4341	16.7914	8.1172	5.6116	4.8480	4.6097 → 4.5 = $f(\mathbf{x}^*)$


## (四) 初始可行内点的求法

### 1、约束不可行性直接最小化法

采用如下的外点惩罚函数型目标函数：

$$f(x) = \sum_{i=1}^l [\max(0, g_i(x) + \varepsilon)]^2$$

求解无约束问题  $\min f(x)$ ，若  $\min f(x^{(0)})=0$ ，则得到的极小点  $x^{(0)}$  将是一个严格的内点，即  $g_i(x^{(0)}) \leq -\varepsilon$



$\varepsilon$ 称为容差参数，不能取得太大，否则可能造成问题无解。

此法常用，但当约束较多且高度非线性时，目标函数较复杂，计算较困难。

## 2、随机选择法

随机事件：布朗运动，抛硬币时出现正反面 ...

随机数：在[ 0,1]均匀分布

计算机产生的随机数为“伪随机数”，按一定的算法或程序产生。如

<b>8520478</b> $\xrightarrow{x^2}$	<b>72598545348484</b> $\xrightarrow{x^2}$	<b>35825647615209</b> $\xrightarrow{x^2}$	<b>68169395938576</b> $\xrightarrow{x^2}$	<b>2869497093681</b>
<b>0. 8520478</b>	<b>0. 5985453</b>	<b>0. 8256476</b>	<b>0. 1693959</b>	<b>0. 6949709</b>

<b>48298455184681</b> $\xrightarrow{x^2}$	<b>8907544671601</b> $\xrightarrow{x^2}$	<b>569220454089</b> $\xrightarrow{x^2}$	<b>85016771966116</b> $\xrightarrow{x^2}$	<b>.....</b>
<b>0. 2984551</b>	<b>0. 0754467</b>	<b>0. 9220454</b>	<b>0. 0167719</b>	<b>.....</b>

随机选择法产生初始可行内点的步骤:

(1) 估计变量 $\mathbf{x}$ 各分量 $x_i$ 的上下限:

$$a_i \leq x_i \leq b_i \quad (i=1,2,\dots,n)$$

(2) 产生试验点 $\mathbf{x}$ , 各分量取为:

$$x_i = a_i + R_i(b_i - a_i) \quad (i=1,2,\dots,n)$$

$R_i$ 为计算机产生的伪随机数

(3) 验证试验点是否满足约束条件

$$g_i(\mathbf{x}) < 0 \quad (i=1,2,\dots,l)$$

若满足, 即得可行内点 $\mathbf{x}^{(0)}$ , 否则回(2)

此法只适用于小规模问题

### § 3 外点法与内点法的比较

(一) 优点：适用范围广，对函数 $f(x)$ ,  $g_i(x)$ ,  $h_j(x)$ 无特殊要求；使用方便，只需用解无约束问题的算法；比较有效，所以常用

(二) 缺点：(1) 工作量大，必须求解一系列无约束问题；

(2) 参数 $M_k$ ,  $r_k$ 的选取对收敛速度影响大；

(3)  $M_k \rightarrow +\infty$ 或 $r_k \rightarrow 0$ ，惩罚函数变得越来越病态，使计算困难。

(三) 各自特点：

- 1、内点法要求初始点为可行内点，外点法无此要求；
- 2、内点法不适用于等式约束问题（老），外点法可用于所有约束问题；
- 3、当迭代点进入可行域中时，外点法立即得到原问题的最优解，而内点法无此特点；
- 4、外点法的惩罚函数在边界上可微性差，选无约束方法时受限制
- 5、内点法的迭代点都是可行点，而外点法的迭代点经常是不可行点，实际问题可能不允许

## § 增广Lagrange乘子法(ALM法)

至此已讨论过的约束问题解法:

- Lagrange乘子法:** 最后化为用最小二乘法求解非线性方程组问题, 目标函数复杂
- 惩罚函数法:** 转化为求解一系列无约束问题, 当 $M_k \rightarrow +\infty$ 或 $r_k \rightarrow 0$ 时, 惩罚函数在边界处很陡, Hesse矩阵病态程度严重, 计算可能出现困难

- 1969年Powell等人提出将两者结合起来, 成为增广Lagrange乘子法。
- 后来Fletcher等人对此法进行了改进, 使其成为一个有效的方法, 在收敛速度和数值稳定性上都比简单的惩罚函数法优越。
- 增广Lagrange乘子法的主要思想: 在惩罚函数中引入Lagrange乘子, 或在Lagrange函数中引入惩罚项, 试图在惩罚因子 $M_k$ 不太大的情况下, 通过调节Lagrange乘子, 逐次求解无约束问题, 逼近原约束问题的最优解。

### § 6.3.1 解等式约束问题的ALM法

$$\begin{cases} \min f(x) \\ \text{s.t. } h_j(x) = 0 \quad j=1,2,\dots,m \end{cases}$$

引入增广Lagrange函数

Lagrange函数  $L(x, \mu)$

惩罚项

$$A(x, \mu, M_k) = f(x) + \sum_{j=1}^m \mu_j h_j(x) + M_k \sum_{j=1}^m [h_j(x)]^2$$

考察一下惩罚项对  $x$  的梯度  $\nabla_x \{M_k \sum_{j=1}^m [h_j(x)]^2\} = 2M_k \sum_{j=1}^m h_j(x) \nabla h_j(x) \xrightarrow{\text{当 } x \in S \text{ 时}} 0$

所以，当  $x$  为可行点时，固定  $M_k$ ，有  $\nabla_x A(x, \mu, M_k) = \nabla_x L(x, \mu)$

若存在  $x^*$  及  $\mu^*$ ，使  $\nabla_x A(x^*, \mu^*, M_k) = 0$ ，则有  $\nabla_x L(x^*, \mu^*) = 0$

即对于  $\mu = \mu^*$  及某个固定的  $M_k$ ，若  $x^*$  为  $A(x, \mu, M_k)$  的无约束极小点，则  $x^*$  是原问题的极小点

对函数  $A(x, \mu^*, M_k)$  只要进行一次无约束最优化就可求得原约束问题的极小点  $x^*$

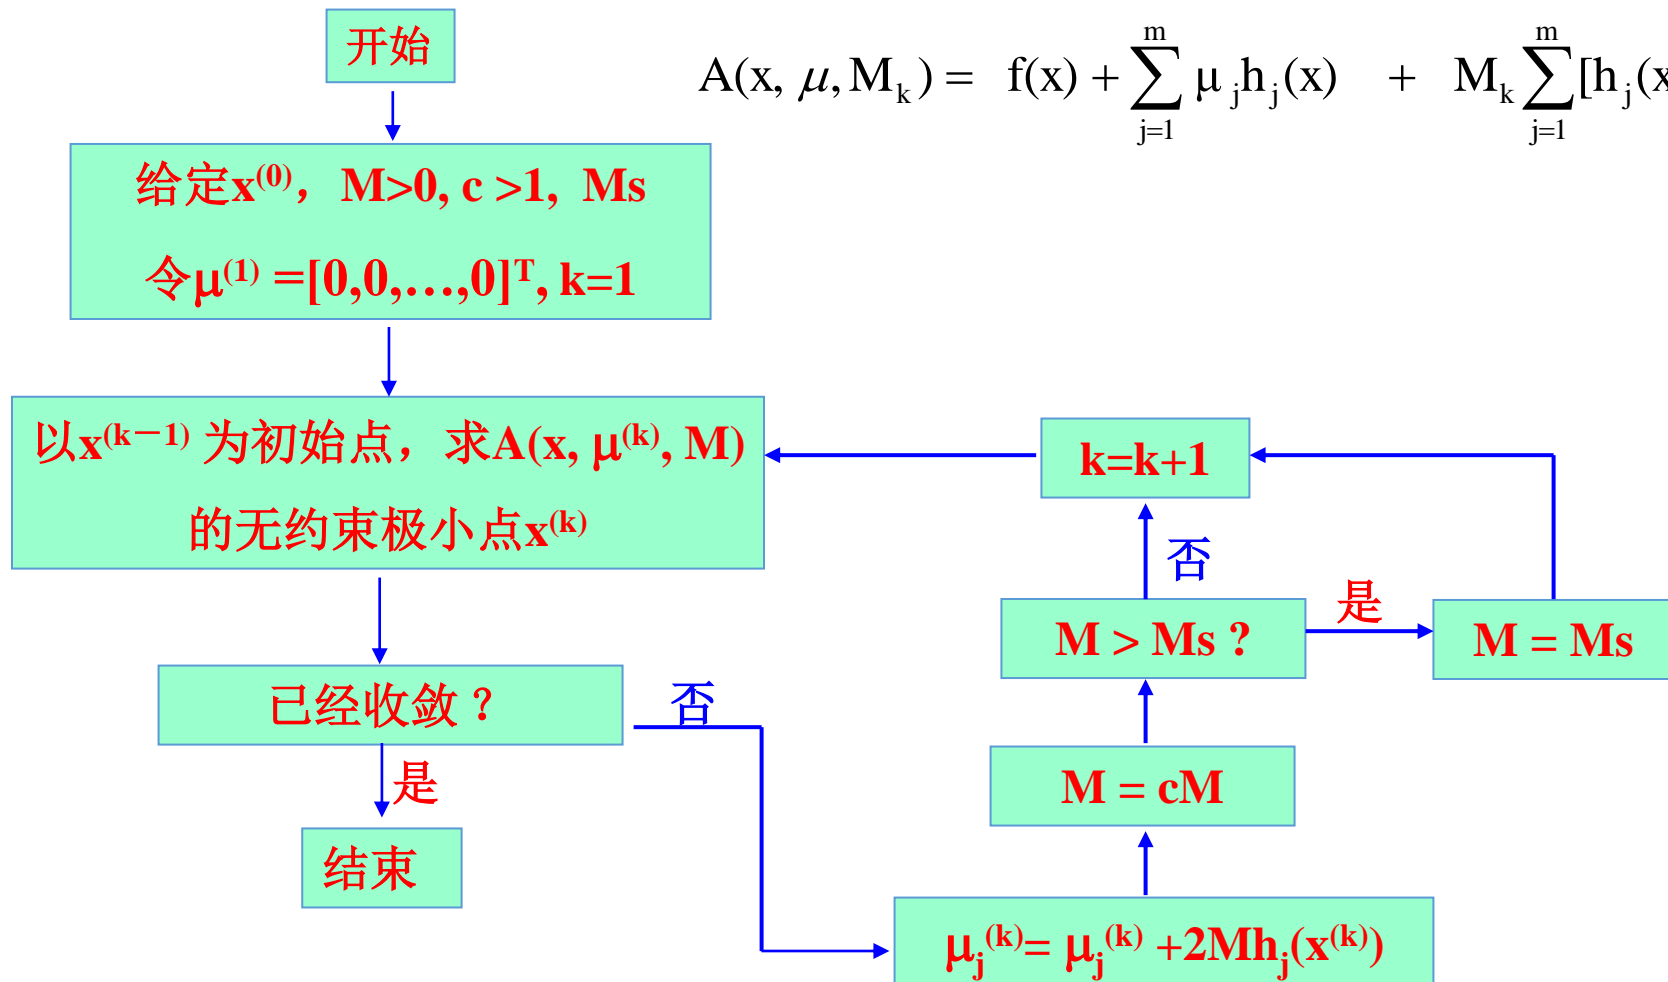


对函数 $A(x, \mu^*, M_k)$ 只要进行一次无约束最优化就可求得原约束问题的极小点 $x^*$

？问题是事先并不知道 $\mu^*$ ？

对策：用迭代的办法，从任意的 $\mu$ （通常取为零或单位向量）逼近 $\mu^*$

$$A(x, \mu, M_k) = f(x) + \sum_{j=1}^m \mu_j h_j(x) + M_k \sum_{j=1}^m [h_j(x)]^2$$



例 用增广Lagrange乘子法解问题

$$\begin{cases} \min f(\mathbf{x}) = x_1^2 + x_2^2 \\ \text{s.t. } h(\mathbf{x}) = x_1 + x_2 - 1 = 0 \end{cases}$$

解： 用Lagrange乘子法解得 $\mathbf{x}^*=[x_1^*, x_2^*]^T=[0.5, 0.5]^T, \mu^*=-1$

增广Lagrange函数为  $A(\mathbf{x}, \mu, M_k) = x_1^2 + x_2^2 + \mu(x_1 + x_2 - 1) + M_k (x_1 + x_2 - 1)^2$

在下面的三种情况中，保持  $M_k=1$

1、 初始取 $\mu^{(1)}=0$

无约束问题求解次数	$\mu$	$x_1=x_2$	$h(\mathbf{x})$
1	0.0000	0.33333	-0.33333
2	-0.6667	0.44444	-0.11111
3	-0.8889	0.48148	-0.03704
4	-0.9630	0.49382	-0.01235
5	-0.9877	0.49794	-0.00041

2、 初始取 $\mu^{(1)}=-2$

无约束问题求解次数	$\mu$	$x_1=x_2$	$h(\mathbf{x})$
1	-2.0000	0.66667	0.33333
2	-1.3333	0.55556	0.11111
3	-1.1111	0.51852	0.03704
4	-1.0370	0.50618	0.01235
5	-1.0123	0.50205	0.00041

3、 初始取 $\mu^{(1)}=-1$

求解一次就得

$$x_1^*=x_2^*=0.5$$

## § 解不等式约束问题的ALM法

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) \leq 0 \quad i=1,2,\dots,l \end{cases}$$

首先引入松弛变量 $w_i$ ，把不等式约束化为等式约束

$$g_i(\mathbf{x}) + w_i^2 = 0 \quad i=1,2,\dots,l$$

$$A(\mathbf{x}, \lambda, \mathbf{w}, M_k) = f(\mathbf{x}) + \sum_{i=1}^l \{ \lambda_i [g_i(\mathbf{x}) + w_i^2] + M_k [g_i(\mathbf{x}) + w_i^2]^2 \}$$

这样可在 $M_k$ 不太大的情况下，通过调节Lagrange乘子，逐次求解无约束问题。

### § 6.3.3 解一般约束问题的ALM法

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) \leq 0 \quad i=1,2,\dots,l \\ h_j(\mathbf{x}) = 0 \quad j=1,2,\dots,m \end{cases}$$

首先引入松弛变量 $w_i$ ，把不等式约束化为等式约束

$$A(\mathbf{x}, \mu, \lambda, \mathbf{w}, M_k) = f(\mathbf{x}) + \sum_{i=1}^l \{ \lambda_i [g_i(\mathbf{x}) + w_i^2] + M_k [g_i(\mathbf{x}) + w_i^2]^2 \} + \sum_{j=1}^m \{ \mu_j h_j(\mathbf{x}) + M_k [h_j(\mathbf{x})]^2 \}$$

这样可在 $M_k$ 不太大的情况下，通过调节Lagrange乘子，逐次求解无约束问题。

## ALM法的特点:

- (1) 方法对 $M_k$ 比较不敏感, 不需要将 $M_k$ 增加到无穷大;
- (2) 精确地达到 $g_i(x) = 0$  和  $h_j(x) = 0$  是可能的;
- (3) 可通过更新Lagrange乘子的值来实现迭代的加速;
- (4) 初始点可以是可行点, 也可以是不可行点;
- (5) 达到最优点处, 由值 $\lambda_i^* \neq 0$ 可自动识别出哪些是起作用约束;
- (6) 如果各个无约束子问题能顺利求解, 那么  $x^* = \lim x^{(k)}$  是一个K-T点;
- (7) 如果 $M_k$ 选得合理, 那么  $\min A(x, \lambda, \mu, M_K, w)$  的难度与 $\min f(x)$ 差不多;
- (8)  $\lambda, \mu, M_K$ 的更新规则是简单的, 不需要额外的计算量;
- (9) 虽然仍要解一系列无约束问题, 但是由于 $M_k$ 是某个有限值, 因而不会出现惩罚函数法中的病态现象, 比惩罚函数法有更好的效果。

$$\lambda_i^* g_i(x^*) = 0$$

## 约束直接搜索法

Lagrange乘子法、惩罚函数法等均是对约束条件进行隐含或间接处理，将原问题化为无约束问题求解。

工程问题经常出现函数的导数不连续或不存在或难求的情况，则只能利用目标函数和约束函数的函数值进行约束直接搜索。


约束直接搜索法的缺点是计算量大，适用于维数低、函数复杂、精度要求不太高的问题。优点是准备时间和准备工作量小，搜索逻辑简单。

两类约束直接搜索法 { 无约束直接搜索法的改造推广  
试验点的随机选择为基础


## § 约束直接搜索法的解题准备

### (一) 将问题中的等式约束消去

对不等式约束问题 $[g_i(x) \leq 0]$ ，可使用无约束问题的直接搜索法，加上步长回缩步骤，能保证迭代点的下降且可行。



对等式约束问题 $[h_j(x) = 0]$ ，若使用无约束直接搜索法，则不能保证迭代点一定是可行下降点



所以必须首先采用消元法等消去等式约束

## (二) 寻找一个初始可行点

a. 惩罚函数最小化法

b. 随机选择法

c. 序列约束最小化方法